



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

Laboratorinis darbas
Dirbtinis neuronas

Lukas Janušauskas

Darbo vadovas : Prof. Dr. Viktor Medvedev

Vilnius
2025

Santrauka

Šio darbo tikslas yra ištirti neurono veikimą klasifikacijos kontekste. Neuroniniai tinklai yra bene svarbiausia dirbtinio intelekto pažangos dalis dėl jų efektyvumo tiek pramonėje, tiek mokslo srityse, sprendžiant prognozes, anomalijų detekcijas, vaizdo atpažinimo ir begalę kitų užduočių.

Susipažinimui su neuroniniais tinklais, ištirtas paprasčiausios įmanomas neuroninis tinklas: vienas neuronas. Šis neuronas sukurtas su ribotu skaičiumi įvesties kintamųjų ir aktyvacijos funkcijų, o jo išeiga buvo pritaikyta klasifikacijos užduočiai. Duomenis klasifikacijai sugeneravome tokiu būdu, kad klasės būtų tiesiškai atskiriamos. Tuomet suradome svorius, kurie klasifikuoja šiuos duomenis 100 % tikslumu, panaudojus grubų algoritmą, panašų į tinklelinę paiešką (angl. grid search).

Apibendrinant, neuroninis tinklas, panaudojus įvairias aktyvacijos funkcijas, gali klasifikuoti tiesiškai atskiriamus duomenis. Pasitelkus algoritmą, įkvėptą tinklelinės paieškos, galima rasti daug galimų variantų. Šie variantai gauti su slenkstine ir sigmoidine funkcijomis tarpusavyje nesiskiria dėl to, kaip buvo implementuotas tiesiškai atskiriamų duomenų generavimas.

Iliustracijų sąrašas

1	Sugeneruoti tiesiškai atskirtini duomenys	4
2	Tiesės ir atitinkami vektoriai, gauti iš optimalių svorių rinkinių	6

Lentelių sąrašas

1	Svorių rinkiniai su abejomis aktyvacijos funkcijomis	6
---	--	---

Žymėjimų ir trumpinių sąrašas

f aktyvacijos funkcija

σ sigmoidinė aktyvacijos funkcija

r poliarine koordinate išreikšto vekroiaus ilgis

θ poliarine koordinate išreikšto vekroiaus kampas

DNT dirbtinis neuroninis tinklas

Turinys

Santrauka	1
Iliustracijų sąrašas	2
Lentelių sąrašas	2
Žymėjimų ir trumpinių sąrašas	2
1. Dirbtinis neuronas	4
1.1. Duomenų generavimas	4
1.2. Neurono realizacija	5
1.3. Optimalių svorių radimas	5
2. Išvados	7

1. Dirbtinis neuronas

1.1. Duomenų generavimas

Užduotyje prašoma sugeneruoti duomenis iš dviejų klasių, kurie būtų tiesiškai atskiriami. Todėl pateikiu tiesinio atskirtinumo apibrėžimą:

1.1..1 Apibrėžimas. Tarkime turime duomenis $X = \{x_i\}_{i=1,\dots,n}$, kur $x_i \in \mathbb{R}^m$, ir klases $y_i \in \{0, 1\}$. Jei egzistuoja svoriai $w_i \in \mathbb{R}$ ir poslinkis $b \in \mathbb{R}$, su kuriais kiekvienam i galioja:


$$y_i = \begin{cases} 0, & \text{kai } \sum_{i=1}^m w_i x_i + b < 0 \\ 1, & \text{kai } \sum_{i=1}^m w_i x_i + b \geq 0 \end{cases} \quad (1)$$

Apibendrinus, duomenys yra teisiškai atskirtini, jei egzistuoja tiesė, kuri skiria klases.

Duomenys generuojami, remiantis polinėmis koordinatėmis. Pirmosios klasės (klasė - 0) taškai turės kampą θ intervale $[25^\circ, 44^\circ]$ ir atstumus r intervale $[5, 15]$. Antrosios klasės (klasė - 1) taškai turės kampą θ intervale $[45^\circ, 65^\circ]$ ir atstumus r intervale $[5, 15]$. Duomenys paverčiami į polines koordinates pagal formulę:

$$\begin{aligned} x &= r \cdot \cos(\theta) \\ y &= r \cdot \sin(\theta) \end{aligned} \quad (2)$$

Tai sugeneruoja tiesiškai atskirtinus duomenis, kadangi pirmojoje klasėje visada $x > y$, o antrojoje: $y > x$.



1 pav. Sugeneruoti tiesiškai atskirtini duomenys

1.2. Neurono realizacija

Šiuos duomenis klasifikuoti sukurtas paprasčiausias DNT - vienas neuronas.

Neuronas apibrėžiamas, implementavus Python klasę `PaprastasNeuronas`, kurioje implementuota inicializacija, svorių priskyrimas, išvesties apskaičiavimas ir klasifikavimas. Neurono aktyvacijos funkcijos yra implementuojamos ne toje klasėje, tačiau atskirai, jų apibrėžimai pateikiami šiame skyriuje.

1.2..1 Apibrėžimas (Slenkstinė aktyvacijos funkcija). Slenkstinė aktyvacijos funkcija (angl. binary step), apibrėžiama.

$$f(x) = \begin{cases} 0, & \text{jei } x < 0, \\ 1, & \text{jei } x \geq 0 \end{cases} \quad (3)$$

1.2..2 Apibrėžimas (Sigmoidinė aktyvacijos funkcija). Sigmoidinė aktyvacijos funkcija (angl. binary step), apibrėžiama.

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4)$$

Neurono svoriai inicializuojami nuliui, taip pat priskiriama aktyvacijos funkcija, jei funkcija parenkama tokia, kokios nėra tarp implementuotų, iš karto iškeliamas `AssertionError` klaida. Implementuota funkcija `set_weights`, kurios įvestis yra svorių kortėžas (angl. tuple), kuris leidžia priskirti neurono svorius ir poslinkį. Neurono išvestis z apskaičiuojama pagal formulę $z = f(w_1x_1 + w_2x_2 + b)$. Klasifikuojant išvestį suapvaliname: jei $z < 0.5$, grąžiname 0, jei $z \geq 0.5$, grąžiname 1.

1.3. Optimalių svorių radimas

Optimalūs DNT svoriai randami iteruojant per skaičių trejetų (w_1, w_2, b) kombinacijas, esančias intervale $[-1, 1]$. Iteruojant per svorių rinkinius, kas kartą tikrinama, ar su tuo rinkiniu pasiekiamas 100 % klasifikavimo tikslumas visame duomenų rinkinyje. Kadangi reikia trijų tokių rinkinių, gavus trečiąjį, sustojama ir grąžinama.

Algoritmas 1 DNT svorių paieška

Require: `class_1`, `class_2` (klasifikavimo duomenų rinkiniai)

Initialize `results` $\leftarrow \emptyset$

Generate grid $G \subset \{(x, y, z) : x, y, z \in [-1, 1]\}$ su 10 elementų kiekvienai dimensijai

for `point` $\in G$ **do**

if $|\text{results}| \geq 3$ **then**

return `results`

end if

if `CheckAllClassified(class_1, class_2, point)` **then**

$\text{results} \leftarrow \text{results} \cup \{\text{point}\}$

end if

end for

return `results`

Ši procedūra buvo atlikta su slenkstine ir sigmoidine funkcijomis. Gautus svorius pristatome lentelėje, svoriai pateikiami forma (w_1, w_2, b) :

Eil. Nr.	Slenkstinė aktyvacijos funkcija	Sigmoidinė aktyvacijos funkcija
1	(0,78; -1,00; -0,78)	(0,78; -1,00; -0,78)
2	(0,78; -1,00; -1,00)	(0,78; -1,00; -1,00)
3	(1, -1, -1)	(1, -1, -1)


1 lentelė. Sviurių rinkiniai su abejomis aktyvacijos funkcijomis

Pastebime, kad tiek su sigmoidine, tiek su slenkstine aktyvacijos funkcija, gauti vienodi rezultatai. Šį rezultatą gavome, tikėtina, dėl to, kad duomenys yra visiškai tiesiškai atskirtini, o ir neuroninio tinklo struktūra yra minimali, taigi nėra vietos atsirasti skirtumams tarp sigmoidinės ir slenkstinės funkcijos.


Iliustruoti šiuos duomenis pasirinkome paprasčiausias tieses, kurios leis vizualiai patikrinti, ar tikrai duomenis teisingai klasifikuoja. Šios tiesės formulė, implementuojant jos brėžimą Python buvo:

$$x_2 = \frac{w_1 x_1 + b}{-w_2} \quad (5)$$

Be to, pavaizduojant gautus svorius, pateikiame ir vektorius, kurių koordinatės būtų lygios svoriams (w_1, w_2) . Kad vektoriai liestų grafiką, vektoriaus pradžios koordinatės yra lygios $(0, b)$.



(a) Tiesės gautos su slenkstine aktyvacijos funkcija



(b) Tiesės gautos su sigmoidine aktyvacijos funkcija

2 pav. Tiesės ir atitinkami vektoriai, gauti iš optimalių sviurių rinkinių

Matome, kad šiuo būdu gauti svoriai sėkmingai klasifikuoja generuotus duomenis su 100 % tikslumu.

2. Išvados

Šiame darbe ištirtas vieno neurono dirbtinis neuroninis tinklas, kuris buvo pritaikytas klasifikavimo užduočiai. Šis neuronas turėjo lygiai du įvesties kintamuosius ir apsiribojome dvejomis aktyvacijos funkcijomis: sigmoidine ir slenkstine (angl. binary step). Šio neurono svorių optimizavimas atliktas su grubiu (angl. brute force) algoritmu, kurio implementacija minimaliai skiriasi nuo tinklelinės paieškos algoritmo.

Neurono pajėgumą ištestavome su tiesiškai atskirtiniais duomenimis, kuriuos sugeneravome panaudodami polines koordinates. Neuronas sėkmingai surado daugiau nei vieną tinkamą svorių rinkinį tiek su sigmoidine, tiek su slenkstine aktyvacijos funkcijomis, taigi tiesiškai atskirtiniams duomenims klasifikuoti neuroninis tinklas yra tinkama architektūra. Nepastebėjome jokio skirtumo tarp svorių, gautų su slenkstine ir sigmoidine funkcijomis. Skirtumo nebūvimas yra pasėkėmė paprasto neuroninio tinklo architektūros ir grubaus svorių suradimo algoritmo.

Apibendrinant, jau paprastas neuronas yra pajėgus klasifikuoti tiesiškai atskirtinus duomenis, nepriklausomai nuo klasikinių aktyvacijų funkcijų pasirinkimo. Taip pat gaunami svoriai yra nepriklausomi nuo aktyvacijos funkcijos paprastu atveju, kadangi skirtumai atsiranda tik su labiau komplikuotomis architektūromis ir ieškant svorių kitais būdais tokiais kaip klaidos sklidimu atgal (angl. backpropagation).