



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

Laboratorinis darbas

**Vieno neurono mokymas sprendžiant klasifikavimo
uždavinį**

Lukas Janušauskas

Laboratorinio darbo vadovas : Doc. dr. Viktor Medvedev

Vilnius
2025

Santrauka

Šio darbo tikslas yra pirmojo laboratorinio darbo metu sukurtam neuronui pridėti galimybę gradientinio nusileidimo metodais nustatyti svorius, klasifikuojant krūties vėžio naviko tipą. Atliekant darbą, bus analizuojami skirtumai tarp stochastinio ir paketinio gradientinių nusileidimų.

Darbe naudojami du optimizavimo algoritmai: stochastinis gradientinis nusileidimas ir paketinis gradientinis nusileidimas. Abejais atvejais apmokomas neuronas ir įvertinamas neurono tikslumas minėtiems duomenims klasifikuoti visuose rinkiniuose, tiek mokymo, tiek validavimo ir testavimo. Paketinio ir stochastinio gradientinio nusileidimo metodais gautų neuronų tikslumai ir mokymo trukmės palyginamos. Taip nustatoma, kaip gradientinio nusileidimo tipas daro įtaką rezultatams ir apmokymo trukmei. Be to, palyginami treniravimo ir validavimo aibėse apskaičiuotų tikslumo bei paklaidos reikšmės skirtingų epochų metu, siekiant įvertinti modelio generalizaciją ir konvergavimą. Siekiant nustatyti geriausią mokymosi greitį abejais atvejais, palyginamos tikslumo ir paklaidų reikšmės, apmokius neuroną, tiek naudojant stochastinį, tiek paketinį nusileidimą su įvairiomis mokymosi greičio reikšmėmis.

Pastebėta tai, kad stochastinio gradientinio nusileidimo metodu, gaunamas geresnis tikslumas, nei treniruojant paketinio gradientinio nusileidimo metodu. Reikšmingas skirtumas tarp stochastinio ir paketinio nusileidimo mokymo trukmės nebuvo rastas. Pastebėjome, kad pradinio modelio (neatrinkus optimalių hiperparametrų) generalizacija yra pakankamai gera stochastinio gradientinio nusileidimu atveju. Tačiau paketinio nusileidimo atveju, mokymosi greičio hiperparametro (angl. *hyperparameter*) per maža reikšmė, nulėmė tai, jog duoto epochų skaičiaus neužteko kokybiškai apmokyti neurono. Mokymosi greičio eksperimentas davė skirtingus rezultatus, taikant skirtingus nusileidimo metodus; skirtumas tarp šių optimalių mokymosi greičio reikšmių iliustruoja dar vieną skirtumą tarp stochastinio ir paketinio nusileidimų.

Taigi, šis darbas iliustruoja skirtumus tarp stochastinio ir paketinio gradientinių nusileidimų, kas sekančiuose darbuose gali padėti atsirinkti, kuris metodas yra tinkamesnis. Taip pat šis darbas gali padėti nuspręsti, nuo kokių hiperparametrų pradėti, kuriant vieno neurono neuroninį tinklą su vienu iš šių optimizavimo metodų.

Raktiniai žodžiai: Dirbtinis intelektas, klasifikacija, neuroniniai tinklai.

Iliustracijų sąrašas

1	Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu	8
2	Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu	9
3	Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu	10
4	Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu	10
5	Paklaidos reikšmės su skirtingais mokymosi greičiais ir nusileidimo algoritmais	11
6	Tikslumo reikšmės su skirtingais mokymosi greičiais ir nusileidimo algoritmais	11
7	Mokymo trukmė, treniruojant neuroną stochastiniu ir paketiniu gradientiniais nusileidimais	12
8	Klasifikavimo tikslumas, treniruojant neuroną stochastiniu ir paketiniu gradientiniais nusileidimais	13

Lentelių sąrašas

1	Duomenų rinkinyje „Breast Cancer Wisconsin (Original)“ esantys kintamieji [Gin08] .	6
2	Stochastinio gradientinio nusileidimo metodu treniruoto neurono svoriai su pradiniais parametrais	7
3	Neurono paklaida ir tikslumas, treniravus su stochastiniu nusileidimu su pradiniais parametrais, visuose rinkiniuose	7
4	Paketinio gradientinio nusileidimo metodu treniruoto neurono svoriai su pradiniais parametrais	7
5	Neurono paklaida ir tikslumas, treniravus su paketiniu nusileidimu su pradiniais parametrais, visuose rinkiniuose	8
6	Optimalaus neurono rezultatai	14
7	Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuroną stochastiniu gradientiniu nusileidimu	17
8	Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuroną stochastiniu gradientiniu nusileidimu	20
9	Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuroną stochastiniu gradientiniu nusileidimu	23
10	Testiniai duomenys ir optimalaus neurono klasifikuotos reikšmės	27

Turinys

Santrauka	2
Iliustracijų sąrašas	3
Lentelių sąrašas	3
1. Gradientinio nusileidimo metodai	5
1.1. Paketinis gradientinis nusileidimas	5
1.2. Stochastinis gradientinis nusileidimas	5
2. Eksperimentai	6
2.1. Duomenų aprašymas	6
2.2. Pradinis modelis	6
2.3. Modelio generalizacija	8
2.4. Mokymosi greičio optimizavimas	11
2.5. Gradientinio nusileidimo metodų palyginimas	12
3. Galutinis modelis	14
4. Kodo ir duomenų prieinamumas	14
5. Išvados	15
A Modelių rezultatai po kiekvienos epochos	17
B Treniravimo duomenys ir optimalaus modelio išvestis	27

1. Gradientinio nusileidimo metodai

Šiame darbe bus plačiai naudojami gradientinio nusileidimo metodai: 1) paketinis gradientinis nusileidimas 2) stochastinis gradientinis nusileidimas. Šie metodai bus taikomi surasti optimalias vieno neurono svorių ir poslinkio reikšmes.

1.1. Paketinis gradientinis nusileidimas

Paketinio gradientinio nusileidimo idėja yra sumažinti paklaidą visiems duomenimis ir tai padaryti per vieną iteraciją [Olg25]. Formaliau kalbant, sakykime $E(W)$ - paklaidos funkcija visam duomenų rinkiniui, $E_i(W)$ - paklaidos funkcija i -ajam stebėjimui, $W = (w_0, \dots, w_n)$ - svoriai, o $\eta \in [0,1]$ - mokymosi greitis. Tada paketinis stochastinis nusileidimas kiekvienos iteracijos metu svorius atnaujiną pagal lygybę:

$$w_k := w_k - \eta \nabla E(W) = w_k - \eta \nabla \sum_{i=1}^m E_i(W).$$

Praktiškai kalbant, implementuojant šį algortimą visų pirma apskaičiuojamos paklaidos **visam** rinkiniui ir tik tada apskaičiuojamas gradientas ir atnaujinami svoriai.

1.2. Stochastinis gradientinis nusileidimas

Stochastinio nusileidimo principas yra visiškai priešingas paketinio nusileidimo idėjai. Šiuo metu siekiama, jog i -tojo mokymo duomenų įrašo paklaida būtų kuo mažesnė [Olg25]. Naudojant tuos pačius apibrėžimus kaip ir praeitame skyrelyje, stochastinio gradientinio nusileidimo žingsnį apibūdina lygybė:

$$w_k := w_k - \eta \nabla E_i(W).$$

Praktikoje, tai reikštų, kad kiekviena iteracija pereina tik per vieną įrašą, taigi vienoje epochoje padarome tiek iteracijų, kiek yra stebėjimų. Todėl, teoriškai, šis algoritmas turėtų daugiau užtrukti, nei paketinis nusileidimas.

2. Eksperimentai

2.1. Duomenų aprašymas

Darbo metu bus bandoma klasifikuoti naviko tipą (piktybinis ar nepiktybinis). Šiam darbui bus naudojami krūties vėžio duomenys iš *UCI Irvine Machine Learning Repository* [Wol90].

Duomenų rinkinį sudaro 699 stebėjimai ir 10 kintamųjų, iš kurių devyni yra požymiai, o vienas kintamasis nusako naviko klases. Visi kintamieji šiame rinkinyje yra skaitiniai, įskaitant ir klases nusakantį kintamąjį. Pateikiu duomenų stulpelių, esančių šiame rinkinyje, aprašymą (1) lentelėje. Atliekant tyrimą, duomenys buvo permaišomi atsitiktine tvarka, kad klasių reikšmės būtų atsitiktinai išsidėsčiusios. Duomenys padalinti į mokymo, validavimo ir testavimo aibes, taikant standartinį 80 : 10 : 10 santykį. Gautas toks duomenų pasiskirstymas: 546 stebėjimai mokymo duomenų aibėje, 68 - validavimo ir 69 treniravimo aibėje.

1 lentelė. Duomenų rinkinyje „Breast Cancer Wisconsin (Original)“ esantys kintamieji [Gin08]

Kintamojo pavadinimas	Paaiškinimas
Clump_thickness	Naviko plotis (nuo 1 iki 10)
Uniformity_of_cell_size	Ląstelių dydžio vientisumas (nuo 1 iki 10)
Uniformity_of_cell_shape	Ląstelių formos vientisumas (nuo 1 iki 10)
Marginal_adhesion	Marginalinė adhezija (nuo 1 iki 10)
Single_epithelial_cell_size	Vienos epitelio ląstelės dydis (nuo 1 iki 10)
Bare_nuclei	„Nuogas“ branduolys (nuo 1 iki 10)
Bland_chromatin	Švelnus chromatinas (nuo 1 iki 10)
Normal_nuclei	Normalus branduolėlis (nuo 1 iki 10)
Mitoses	Mitozės (nuo 1 iki 10)
Class	Naviko tipas (2 - nepiktybinis, 4 - piktybinis)

2.2. Pradinis modelis

Šio darbo pagrindinis objektas: neuronas, pritaikytas klasifikavimo užduočiai, naudojantis sigmodinę (angl. *sigmoid*) aktyvacijos funkciją. Svoriams inicializuoti naudojama *Xavier* inicializacija [GB10]. Poslinkis inicijuojamas nuliui, o svoriai parenkami atsitiktinai iš tolygaus skirstinio:

$$W_{ij} \sim U\left[-\frac{1}{\sqrt{n}}, \frac{1}{\sqrt{n}}\right].$$

Čia W_{ij} - svoris i -jame sluoksnyje, j -ajame neurone, U - tolygus pasiskirstymas, o n - praėjusio sluoksnio išvesties neuronų skaičius arba, mūsų atveju, tai yra įvesties neuronų skaičius - 9.

Neuroną apmokyti pritaikyti praeitoje dalyje aprašyti optimizavimo metodai. Paklaidos funkcijai (angl. *loss function*) naudojamas vidutinis kvadratinis nuokrypis (angl. *Mean Square Error (MSE)*). Pradžiai, neuronas treniruojamas 150 epochų su mokymosi greičiu $\eta = 10^{-3}$ ir papildomu stabdymo kriterijumi $\text{total}_{\text{error}} < 10$.

Stochastinis gradientinis nusileidimas Su stochastiniu gradientiniu nusileidimu treniruotas neuronas įgavo svorius ir poslinkį, pateiktą (2) lentelėje. Paklaidas ir tikslumą paskutinėje epochoje mokymo, treniravimo ir validavimo aibėse pateikiu (3) lentelėje. Kadangi, buvo treniruojama 150 epochų, mokymo ir validavimo duomenų paklaidas ir tikslumus po kiekvienos epochos pateikiamas priede A. Mokymas užtruko 9,07 sekundes.

2 lentelė. Stochastinio gradientinio nusileidimo metodu treniruoto neurono svoriai su pradiniais parametrais

Svoriai	(−0,150811, 0,617848, 0,199519, − 0,01002, − 0,609619, 0,50237318, − 0,266936, 0,276419, 0,06741001)
Poslinkis	−1,534180

3 lentelė. Neurono paklaida ir tikslumas, treniravus su stochastiniu nusileidimu su pradiniais parametrais, visuose rinkiniuose

Rinkinys	Paklaida	Tikslumas
Mokymo	0,061451	0,934065
Validavimo	0,070283	0,926470
Testavimo	0,014493	0,985507

Kaip ir tikėtasi, paklaida mokymo aibėje yra mažiausia, o tikslumas - didžiausias. Pastebime, kad gaunamas geras tikslumas, taigi vienam neuronui $\eta = 10^{-3}$ ir 150 epochų yra tinkami hiperparametrai, apmokant stochastiniu gradientiniu nusileidimu, sprendžiant naviko tipo klasifikavimo problemą.

Paketinis gradientinis nusileidimas Analogiškai praeitam atvejui, svorius ir poslinkį (4) lentelėje, rezultatus (5) lentelėje ir taip pat paklaidas bei tikslumus po kiekvienos epochos pateikiame priede A. Mokymas šiuo metodu užtruko 8,83 sekundės.

4 lentelė. Paketinio gradientinio nusileidimo metodu treniruoto neurono svoriai su pradiniais parametrais

Svoriai	(−0,080124, 0,313100, 0,1670433, 0,075737, − 0,226296, − 0,205847, − 0,286761, 0,254397, 0,067410)
Poslinkis	−0,004668

Palyginus su stochastiniu nusileidimu gautus rezultatus, pateiktus lentelėje (2), matome, kad gauname visiškai skirtingus svorius, kas mums gali leisti suprasti, jog paketiniu nusileidimu mokytas neuronas neapsimoko (angl. *underfit*).

5 lentelė. Neuronų paklaida ir tikslumas, treniravus su pakietiniu nusileidimu su pradiniais parametrais, visuose rinkiniuose


Rinkinys	Paklaida	Tikslumas
Mokymo	0,21241	0,747253
Validavimo	0,235969	0,750000
Testavimo	0,231884	0,768115

Iš lentelės (5) pastebime, kad tiek validavimo tiek testinių duomenų tikslumas yra didesnis už mokymosi aibėje apskaičiuotą tikslumą. Tai mums įrodo, jog modelis neapsimokė, t.y. neišmoko apsimuoti duomenis generuojančios taisyklės.

2.3. Modelio generalizacija


Tikrinant modelio generalizaciją (angl. *generalization*), gebėjimą klasifikuoti (ar prognozuoti) nematytus duomenis, dažnai iliustruojama paklaidos ar tikslumo priklausomybė nuo epochos mokymo ir validavimo duomenų rinkiniuose. Šis tyrimas turės atskleisti, kaip neuronas, apmokytas su pradiniais hiperparametrais, aprašyta skyrelyje 2.2., geba klasifikuoti mokymo metu nematytus duomenis. Taip pat, šis tyrimas padės nustatyti, ar modelis nėra permokomas (angl. *overfit*), ir, ar nėra neapmokomas (angl. *underfit*).

Grafiškai palyginamos mokymo ir validavimo aibių paklaidos, x -ašyje pažymėjus epochas, o y -ašyje paklaidą po atitinkamos epochos (žr. 1 pav.). Galima pastebėti, kad paklaida validavimo aibėje beveik visose epochose yra didesnė už mokymo aibės. Pastebima tendencija, kad paklaida beveik pastoviai mažėja, o validavimo duomenyse įvertinta paklaida nepradedo augti. Tai atskleidžia, kad modelis nepasiekia taško, nuo kurio pradėtų persitreniruoti.



1 pav. Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu


Toliau, iliustruojama klasifikavimo tikslumo ir epochos priklausomybė, tiek mokymo, tiek validavimo duomenų rinkiniuose (žr. 2 pav.). Gauname panašius rezultatus: validavimo rinkinyje įvertintas tikslumas yra artimas mokymo aibėje gautam tikslumui, tačiau beveik visose epochose mažesnis. Tikslumas beveik pastoviai didėja ir nepasiekiamas taškas, kuriame validavimo duomenyse tikslumas pradėtų mažėti.



2 pav. Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuroną stochastiniu nusileidimu


Taigi, stochastinis gradientinis nusileidimas su mokymosi greičiu $\eta = 10^{-3}$ ir 150 epochų sėkmingai apmoko neuroną, kuris ne tik turi aukštą tikslumą, bet ir gerą generalizaciją. Toliau įsitikinsime, kad su paketiniu nusileidimu gauname priešingą rezultatą.

Paketinio nusileidimo metodu apmokyto neurono paklaidos priklausomybės nuo epochos grafikas (žr. 3 pav.) atskleidžia, jog modelis neapsimokė (angl. *underfit*). Tai galėtų būti pasekmė per mažo mokymosi greičio su per mažo atitinkamo epochų skaičiaus.



3 pav. Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuronų stochastiniu nusileidimu

Šiam pastebėjimui antrina ir tikslumo priklausomybės nuo epochos grafikas (žr. 4 pav.), kadangi matome prastus ir sunkiai interpretuojamus rezultatus: mokymo aibės klasifikavimo tikslumas yra ne tik žemas, bet ir pastovus beveik epochų atžvilgiu. Tai gali paaiškinti tik spėjimas, jog neatlikta pakankamai epochų ir mokymosi greitis per mažas taikytam metodui.



4 pav. Mokymo bei validavimo aibių paklaidos ir epochos priklausomybė, apmokant neuronų stochastiniu nusileidimu


2.4. Mokymosi greičio optimizavimas

Sekantis žingsnis yra nustatyti geriausią apmokymo greitį η tiek stochastinio, tiek paketinio nusileidimo atvejais. Panašu, kad stochastinio nusileidimo atveju, mes esame arti geriausio varianto, tačiau to pačio pasakyti apie paketinį nusileidimą negalime.


Ieškodami geriausio varianto, išbandėme šias mokymo greičio reikšmes: $\{10^{-5}, 10^{-3}, 10^{-1}\}$.

Apmokius neuroną su visais šiais mokymosi greičiais, pasitelkus abu gradientinio nusileidimo metodus, įvertinama paklaida ir klasifikavimo tikslumas. Palyginimui, nubrėžiami linijiniai grafikai (žr. 5, 6 pav.) rezultatų palyginimui tarp mokymosi greičių ir nusileidimo tipo.

Sprendžiant pagal paklaidą (žr. 5 pav.), gauname, jog geriausiai stochastinis gradientinis nusileidimas apmoko neuroną su $\eta = 10^{-3}$. Tuo tarpu, pastebime, jog paketinis gradientinis nusileidimas geriausiai apmokomas su didžiausiu iš parinktų mokymo greičių - $\eta = 0,1$. Tai paaiškina prastus rezultatus, gautus ankstesniuose skyriuose: akivaizdu, jog $\eta = 10^{-3}$ yra neoptimalus mokymosi greitis, apmokant neuroną paketiniu gradientiniu nusileidimu. Šias pastabas paantrina ir klasifikavimo tikslumo rezultatai su įvairiais mokymosi greičiais (žr. 6 pav.).



5 pav. Paklaidos reikšmės su skirtingais mokymosi greičiais ir nusileidimo algoritmais




6 pav. Tikslumo reikšmės su skirtingais mokymosi greičiais ir nusileidimo algoritmais

2.5. Gradientinio nusileidimo metodų palyginimas


1. skyriuje aprašyti gradientinio nusileidimo metodai turi savo privalumus ir trūkumus. Vieną stochastinio gradientinio nusileidimo metodo trūkumą minėtame skyriuje jau buvo pateiktas: stochastinio nusileidimo metodu apmokant modelį, užtrunkame ilgiau, skaičiavimai brangesni. Tačiau, šis skirtumas yra teorinis, jis bus šio tyrimo metu patikrintas empiriškai. Paleisime apmokymo algoritmus ant duomenų ir palyginsime, kaip jie skiriasi, kiek įmanoma sumažinant tam tikrus kompiuterio pajėgumo svyravimus. Be to, ankstesniuose tyrimuose pastebėjome didelį skirtumą tarp paketinio bei stochastinio nusileidimo metodais apmokyto neurono klasifikacijos tikslumo, taigi šio tyrimo metu galima bus patikrinti, ar ši tendencija galioja, pritaikius atitinkamai optimalius mokymosi greičius.

Atlikus skaičiavimus gauta, jog minėtais metodais apmokomo neurono mokymo trukmė reikšmingai nesiskiria. Užtruktas laikas, grafiškai iliustruotas stulpeline diagrama (žr. 7 pav.), nesiskiria tarp gradientinio nusileidimo ir stochastinio, ypač turint omenyje sklaidą, kuri iliustruojama klaidos juostomis (angl. *error bars*). Tai gali paaiškinti faktas, kad kuriant programas, nebuvo naudojami matriciniai skaičiavimai, kuriuos pagreitinus su grafiniais procesoriais (angl. *GPU*), atsirastų skirtumas tarp šių optimizavimo metodų.



7 pav. Mokymo trukmė, treniruojant neuroną stochastiniu ir paketiniu gradientiniais nusileidimais

Tačiau, įvertinus paklaidą ir klasifikacijos tikslumą (naudojama testavimo aibė), pastebimas skirtumas tarp gradientinio nusileidimo metodų. Net ir pritaikius optimalias reikšmes abiemis metodams, stochastinis vis tiek pranašesnis (žr. 8 pav.), kadangi jis turi mažesnę paklaidą ir klasifikavimo tikslumas yra kiek didesnis už gautą, apmokant neuroną paketiniu nusileidimu.



8 pav. Klasifikavimo tikslumas, treniruoiant neuroną stochastiniu ir paketiniu gradientiniais nusileidimais

3. Galutinis modelis

Galutiniam modeliui apmokyti panaudotas stochastinis gradientinis nusileidimas su $\eta = 10^{-3}$, remiantis šio tyrimo metu atlikta analize. Žemiau, 6 pateikti visi aktualūs duomenys, išskyrus testavimo įrašų ir gautų reikšmių lentelę, kuri yra pridėta priede B.

6 lentelė. *Optimalaus neurono rezultatai*

Svoriai	(−0,150811, 0,617848, 0,199519, − 0,01002, − 0,609619, 0,502373, − 0,266935, 0,276418, 0,067410)
Poslinkis	−1,534180
Epochų skaičius	150
Paklaida mokymo duomenų paskutinėje epochoje	0,061451
Paklaida validavimo duomenų paskutinėje epochoje	0,070283
Klasifikavimo tikslumas mokymo duomenų paskutinėje epochoje	0,934066
Klasifikavimo tikslumas validavimo duomenų paskutinėje epochoje	0,926471
Paklaida testavimo aibėje	0,014492
Klasifikavimo tikslumas testavimo duomenyse	0,985507

4. Kodo ir duomenų prieinamumas

Tiek kodą, tiek kitus failus galima pasiekti atviroje github repozitorijoje [Jan25].

5. Išvados

Šio darbo metu buvo apmokytas neuronas, naudojant stochastinį ir gradientinį nusileidimą. Atlikti eksperimentai, kurie padėtų patikrinti modelio generalizaciją, išrinkti optimalų mokymo greitį ir palyginti nusileidimo metodus.

Padarytos šios išvados apie neurono apmokymą ir skirtumus tarp gradientinio nusileidimo:

- Neuronas, apmokytas stochastiniu gradientiniu nusileidimu ir optimizuotu mokymo greičiu pasiekia ne tik aukštą klasifikavimo tikslumą ir mažą tikslumą, bet ir turi gerą generalizaciją.
- Paketiniui gradientiniui nusileidimui optimaliai apmokyti reikia aukštesnės mokymosi greičio reikšmės, o stochastiniui - mažesnės.
- Treniruojant iteratyviai, nenaudojant matricinių skaičiavimų ir grafinio procesoriaus pagreitinių, skirtumo mokymo laike tarp gradientinio nusileidimo modelių.
- Stochastinis gradientinis nusileidimas apmoko tikslesnį modelį, net ir optimizavimus abiejų metodų hiperparametrus.

Literatūros sąrašas

- [GB10] X. Glorot, Y. Bengio. „Understanding the difficulty of training deep feedforward neural networks“. Iš: *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*. Sudarė Y. W. Teh, M. Titterton. Tomas 9. Proceedings of Machine Learning Research. Chia Laguna Resort, Sardinia, Italy: PMLR, 2010, puslapiai 249–256. URL: <https://proceedings.mlr.press/v9/glorot10a.html>.
- [Gin08] J. Ž. Gintautas Dzemyda Olga Kurasova. *DAUGIAMAČIŲ DUOMENŲ VIZUALIZAVIMO METODAI*. Vilnius: Mokslo Aidai, 2008.
- [Jan25] L. Janušauskas. *2 laboratorinis. Kodas*. <https://github.com/lukasjanusauskas/AI-assignments/tree/master/uzd2>. 2025.
- [Olg25] V. M. Olga Kurasova. *Paskaitų konspektas. Dirbtinis neuronas - perceptronas*. 2025. URL: https://emokymai.vu.lt/pluginfile.php/51360/mod_resource/content/14/Dirbtinis_neuronas.pdf.
- [Wol90] W. Wolberg. *Breast Cancer Wisconsin (Original)*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5HP4Z>. 1990.

A Modelių rezultatai po kiekvienos epochos

7 lentelė. Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuroną stochastiniu gradientiniu nusileidimu

Epocha	Treniravimo paklaida	Validavimo paklaida	Treniravimo tikslumas	Validavimo tikslumas
0	0,228246	0,263474	0,741758	0,705882
1	0,228104	0,263232	0,743590	0,705882
2	0,227962	0,262991	0,743590	0,705882
3	0,227821	0,262751	0,745421	0,705882
4	0,227681	0,262512	0,745421	0,705882
5	0,227541	0,262274	0,745421	0,705882
6	0,227401	0,262036	0,745421	0,705882
7	0,227263	0,261800	0,736264	0,705882
8	0,227124	0,261564	0,736264	0,705882
9	0,226987	0,261329	0,736264	0,705882
10	0,226849	0,261095	0,736264	0,705882
11	0,226713	0,260862	0,736264	0,705882
12	0,226577	0,260630	0,734432	0,705882
13	0,226441	0,260398	0,734432	0,705882
14	0,226306	0,260167	0,734432	0,705882
15	0,226172	0,259938	0,734432	0,705882
16	0,226038	0,259709	0,734432	0,705882
17	0,225905	0,259481	0,734432	0,705882
18	0,225772	0,259253	0,736264	0,705882
19	0,225640	0,259027	0,736264	0,705882
20	0,225508	0,258802	0,734432	0,705882
21	0,225377	0,258577	0,734432	0,705882
22	0,225246	0,258353	0,734432	0,705882
23	0,225116	0,258130	0,734432	0,705882
24	0,224987	0,257908	0,734432	0,705882
25	0,224858	0,257686	0,734432	0,705882
26	0,224729	0,257466	0,734432	0,705882
27	0,224601	0,257246	0,734432	0,705882
28	0,224474	0,257027	0,734432	0,705882
29	0,224347	0,256809	0,734432	0,705882
30	0,224221	0,256592	0,736264	0,705882
31	0,224095	0,256375	0,736264	0,705882
32	0,223970	0,256160	0,736264	0,705882
33	0,223845	0,255945	0,736264	0,705882
34	0,223721	0,255731	0,736264	0,705882
35	0,223597	0,255518	0,738095	0,705882
36	0,223474	0,255306	0,739927	0,705882
37	0,223351	0,255094	0,739927	0,705882
38	0,223229	0,254883	0,736264	0,705882
39	0,223107	0,254673	0,736264	0,705882
40	0,222986	0,254464	0,736264	0,705882
41	0,222866	0,254256	0,736264	0,705882

42	0,222746	0,254048	0,736264	0,705882
43	0,222626	0,253842	0,736264	0,705882
44	0,222507	0,253636	0,736264	0,705882
45	0,222388	0,253431	0,736264	0,705882
46	0,222270	0,253226	0,736264	0,705882
47	0,222153	0,253023	0,736264	0,691176
48	0,222036	0,252820	0,736264	0,691176
49	0,221919	0,252618	0,738095	0,691176
50	0,221803	0,252417	0,738095	0,691176
51	0,221688	0,252216	0,738095	0,691176
52	0,221572	0,252017	0,738095	0,691176
53	0,221458	0,251818	0,738095	0,691176
54	0,221344	0,251620	0,738095	0,691176
55	0,221230	0,251422	0,738095	0,691176
56	0,221117	0,251226	0,738095	0,691176
57	0,221004	0,251030	0,738095	0,691176
58	0,220892	0,250835	0,738095	0,691176
59	0,220781	0,250641	0,738095	0,691176
60	0,220669	0,250447	0,738095	0,691176
61	0,220559	0,250254	0,736264	0,691176
62	0,220449	0,250062	0,736264	0,705882
63	0,220339	0,249871	0,736264	0,705882
64	0,220230	0,249681	0,736264	0,705882
65	0,220121	0,249491	0,736264	0,720588
66	0,220012	0,249302	0,736264	0,720588
67	0,219905	0,249114	0,736264	0,720588
68	0,219797	0,248926	0,736264	0,720588
69	0,219690	0,248739	0,736264	0,720588
70	0,219584	0,248553	0,736264	0,720588
71	0,219478	0,248368	0,736264	0,720588
72	0,219372	0,248184	0,736264	0,720588
73	0,219267	0,248000	0,736264	0,720588
74	0,219163	0,247817	0,734432	0,720588
75	0,219059	0,247634	0,734432	0,720588
76	0,218955	0,247453	0,734432	0,720588
77	0,218852	0,247272	0,734432	0,720588
78	0,218749	0,247091	0,734432	0,720588
79	0,218646	0,246912	0,732601	0,720588
80	0,218544	0,246733	0,734432	0,720588
81	0,218443	0,246555	0,734432	0,735294
82	0,218342	0,246378	0,734432	0,735294
83	0,218241	0,246201	0,734432	0,735294
84	0,218141	0,246025	0,734432	0,735294
85	0,218042	0,245850	0,736264	0,750000
86	0,217942	0,245675	0,736264	0,750000
87	0,217843	0,245501	0,736264	0,750000
88	0,217745	0,245328	0,734432	0,750000
89	0,217647	0,245155	0,732601	0,750000
90	0,217549	0,244983	0,734432	0,750000

91	0,217452	0,244812	0,736264	0,750000
92	0,217356	0,244642	0,736264	0,750000
93	0,217259	0,244472	0,736264	0,750000
94	0,217163	0,244303	0,736264	0,750000
95	0,217068	0,244135	0,736264	0,750000
96	0,216973	0,243967	0,738095	0,750000
97	0,216878	0,243800	0,738095	0,750000
98	0,216784	0,243633	0,738095	0,750000
99	0,216690	0,243467	0,738095	0,750000
100	0,216597	0,243302	0,738095	0,750000
101	0,216504	0,243138	0,738095	0,750000
102	0,216411	0,242974	0,738095	0,750000
103	0,216319	0,242811	0,738095	0,750000
104	0,216227	0,242648	0,738095	0,750000
105	0,216136	0,242487	0,739927	0,750000
106	0,216045	0,242325	0,739927	0,750000
107	0,215954	0,242165	0,741758	0,750000
108	0,215864	0,242005	0,741758	0,750000
109	0,215774	0,241846	0,741758	0,750000
110	0,215685	0,241687	0,741758	0,750000
111	0,215596	0,241529	0,741758	0,750000
112	0,215507	0,241372	0,739927	0,750000
113	0,215419	0,241215	0,739927	0,750000
114	0,215331	0,241059	0,741758	0,750000
115	0,215244	0,240903	0,741758	0,750000
116	0,215157	0,240748	0,741758	0,750000
117	0,215070	0,240594	0,745421	0,750000
118	0,214983	0,240440	0,743590	0,750000
119	0,214897	0,240287	0,743590	0,750000
120	0,214812	0,240135	0,743590	0,750000
121	0,214727	0,239983	0,743590	0,750000
122	0,214642	0,239832	0,741758	0,750000
123	0,214557	0,239681	0,741758	0,750000
124	0,214473	0,239531	0,743590	0,750000
125	0,214389	0,239382	0,743590	0,750000
126	0,214306	0,239233	0,743590	0,750000
127	0,214223	0,239085	0,743590	0,750000
128	0,214140	0,238937	0,743590	0,750000
129	0,214057	0,238790	0,743590	0,750000
130	0,213975	0,238644	0,743590	0,750000
131	0,213894	0,238498	0,743590	0,750000
132	0,213812	0,238353	0,743590	0,750000
133	0,213731	0,238208	0,743590	0,750000
134	0,213651	0,238064	0,743590	0,750000
135	0,213570	0,237920	0,747253	0,750000
136	0,213490	0,237777	0,747253	0,750000
137	0,213411	0,237635	0,747253	0,750000
138	0,213332	0,237493	0,747253	0,750000
139	0,213253	0,237351	0,747253	0,750000

140	0,213174	0,237211	0,747253	0,750000
141	0,213096	0,237071	0,747253	0,750000
142	0,213018	0,236931	0,747253	0,750000
143	0,212940	0,236792	0,747253	0,750000
144	0,212863	0,236653	0,747253	0,750000
145	0,212786	0,236515	0,747253	0,750000
146	0,212709	0,236378	0,747253	0,750000
147	0,212633	0,236241	0,747253	0,750000
148	0,212557	0,236105	0,747253	0,750000
149	0,212481	0,235969	0,747253	0,750000

8 lentelė. Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuroną stochastiniu gradientiniu nusileidimu

Epocha	Treniravimo paklaida	Validavimo paklaida	Treniravimo tikslumas	Validavimo tikslumas
0	0,228246	0,263474	0,741758	0,705882
1	0,207602	0,182237	0,666667	0,735294
2	0,190138	0,226922	0,782051	0,735294
3	0,179191	0,163271	0,760073	0,794118
4	0,166576	0,204497	0,818681	0,764706
5	0,158765	0,152419	0,824176	0,838235
6	0,149868	0,184299	0,840659	0,779412
7	0,143954	0,147733	0,844322	0,823529
8	0,138170	0,167387	0,849817	0,808824
9	0,133828	0,145476	0,855311	0,838235
10	0,129982	0,154766	0,858974	0,823529
11	0,126782	0,142964	0,862637	0,838235
12	0,123973	0,145834	0,864469	0,823529
13	0,121499	0,139637	0,868132	0,838235
14	0,119282	0,139410	0,880952	0,838235
15	0,117276	0,135888	0,882784	0,838235
16	0,115446	0,134501	0,884615	0,838235
17	0,113766	0,132139	0,890110	0,838235
18	0,112213	0,130476	0,891941	0,838235
19	0,110771	0,128618	0,895604	0,838235
20	0,109425	0,126998	0,895604	0,852941
21	0,108164	0,125395	0,895604	0,852941
22	0,106976	0,123900	0,899267	0,852941
23	0,105854	0,122462	0,901099	0,852941
24	0,104791	0,121095	0,902930	0,852941
25	0,103779	0,119786	0,901099	0,852941
26	0,102815	0,118534	0,902930	0,852941
27	0,101893	0,117333	0,901099	0,852941
28	0,101009	0,116179	0,901099	0,852941
29	0,100160	0,115071	0,899267	0,852941
30	0,099343	0,114003	0,899267	0,852941
31	0,098556	0,112975	0,901099	0,852941
32	0,097796	0,111982	0,901099	0,852941

33	0,097060	0,111024	0,901099	0,852941
34	0,096348	0,110098	0,901099	0,852941
35	0,095658	0,109202	0,899267	0,882353
36	0,094988	0,108334	0,899267	0,882353
37	0,094337	0,107492	0,899267	0,882353
38	0,093704	0,106676	0,899267	0,882353
39	0,093088	0,105884	0,899267	0,882353
40	0,092487	0,105115	0,901099	0,897059
41	0,091902	0,104367	0,902930	0,897059
42	0,091330	0,103640	0,904762	0,897059
43	0,090772	0,102932	0,904762	0,911765
44	0,090227	0,102242	0,904762	0,911765
45	0,089694	0,101571	0,904762	0,911765
46	0,089173	0,100916	0,904762	0,911765
47	0,088663	0,100278	0,904762	0,911765
48	0,088163	0,099655	0,904762	0,911765
49	0,087673	0,099047	0,906593	0,911765
50	0,087194	0,098454	0,906593	0,911765
51	0,086723	0,097874	0,906593	0,911765
52	0,086262	0,097307	0,906593	0,911765
53	0,085809	0,096753	0,906593	0,911765
54	0,085365	0,096211	0,908425	0,911765
55	0,084928	0,095681	0,908425	0,926471
56	0,084500	0,095162	0,908425	0,926471
57	0,084079	0,094655	0,908425	0,926471
58	0,083665	0,094158	0,908425	0,926471
59	0,083258	0,093671	0,910256	0,926471
60	0,082857	0,093194	0,910256	0,926471
61	0,082463	0,092726	0,912088	0,926471
62	0,082076	0,092268	0,912088	0,926471
63	0,081695	0,091819	0,912088	0,926471
64	0,081319	0,091378	0,912088	0,926471
65	0,080950	0,090946	0,913919	0,926471
66	0,080586	0,090522	0,913919	0,926471
67	0,080227	0,090106	0,915751	0,926471
68	0,079874	0,089698	0,915751	0,926471
69	0,079526	0,089297	0,915751	0,926471
70	0,079183	0,088903	0,915751	0,926471
71	0,078844	0,088516	0,917582	0,926471
72	0,078511	0,088136	0,917582	0,926471
73	0,078182	0,087763	0,917582	0,926471
74	0,077858	0,087396	0,917582	0,926471
75	0,077538	0,087035	0,919414	0,926471
76	0,077222	0,086681	0,919414	0,926471
77	0,076910	0,086332	0,919414	0,926471
78	0,076603	0,085989	0,919414	0,926471
79	0,076299	0,085652	0,919414	0,926471
80	0,076000	0,085320	0,919414	0,926471
81	0,075704	0,084994	0,919414	0,926471

82	0,075412	0,084673	0,921245	0,926471
83	0,075123	0,084356	0,921245	0,926471
84	0,074838	0,084045	0,921245	0,926471
85	0,074557	0,083738	0,921245	0,926471
86	0,074278	0,083437	0,921245	0,926471
87	0,074004	0,083139	0,921245	0,926471
88	0,073732	0,082846	0,921245	0,926471
89	0,073464	0,082558	0,921245	0,926471
90	0,073198	0,082273	0,921245	0,926471
91	0,072936	0,081993	0,921245	0,926471
92	0,072677	0,081716	0,921245	0,926471
93	0,072421	0,081444	0,921245	0,926471
94	0,072167	0,081175	0,923077	0,926471
95	0,071917	0,080910	0,923077	0,926471
96	0,071669	0,080649	0,923077	0,926471
97	0,071424	0,080391	0,923077	0,926471
98	0,071181	0,080137	0,923077	0,926471
99	0,070941	0,079886	0,923077	0,926471
100	0,070704	0,079638	0,924908	0,926471
101	0,070469	0,079393	0,924908	0,926471
102	0,070237	0,079152	0,924908	0,926471
103	0,070007	0,078913	0,924908	0,926471
104	0,069779	0,078678	0,924908	0,926471
105	0,069554	0,078445	0,924908	0,926471
106	0,069331	0,078216	0,924908	0,926471
107	0,069110	0,077989	0,924908	0,926471
108	0,068891	0,077764	0,924908	0,926471
109	0,068675	0,077543	0,924908	0,926471
110	0,068461	0,077324	0,924908	0,926471
111	0,068249	0,077107	0,924908	0,926471
112	0,068039	0,076893	0,924908	0,926471
113	0,067830	0,076681	0,924908	0,926471
114	0,067624	0,076472	0,924908	0,926471
115	0,067420	0,076265	0,924908	0,926471
116	0,067218	0,076060	0,924908	0,926471
117	0,067018	0,075857	0,924908	0,926471
118	0,066819	0,075657	0,924908	0,926471
119	0,066623	0,075459	0,924908	0,926471
120	0,066428	0,075262	0,924908	0,926471
121	0,066235	0,075068	0,924908	0,926471
122	0,066044	0,074875	0,924908	0,926471
123	0,065854	0,074685	0,924908	0,926471
124	0,065666	0,074496	0,924908	0,926471
125	0,065480	0,074309	0,926740	0,926471
126	0,065295	0,074124	0,928571	0,926471
127	0,065112	0,073941	0,928571	0,926471
128	0,064931	0,073759	0,928571	0,926471
129	0,064751	0,073580	0,928571	0,926471
130	0,064573	0,073401	0,928571	0,926471

131	0,064396	0,073225	0,928571	0,926471
132	0,064221	0,073049	0,928571	0,926471
133	0,064047	0,072876	0,928571	0,926471
134	0,063875	0,072704	0,930403	0,926471
135	0,063704	0,072533	0,930403	0,926471
136	0,063535	0,072364	0,930403	0,926471
137	0,063367	0,072196	0,930403	0,926471
138	0,063200	0,072030	0,930403	0,926471
139	0,063035	0,071865	0,930403	0,926471
140	0,062871	0,071701	0,930403	0,926471
141	0,062708	0,071539	0,930403	0,926471
142	0,062547	0,071377	0,932234	0,926471
143	0,062386	0,071217	0,932234	0,926471
144	0,062228	0,071059	0,932234	0,926471
145	0,062070	0,070901	0,932234	0,926471
146	0,061914	0,070745	0,932234	0,926471
147	0,061758	0,070590	0,932234	0,926471
148	0,061604	0,070436	0,934066	0,926471
149	0,061452	0,070283	0,934066	0,926471

9 lentelė. Validavimo ir testavimo aibėse apskaičiuotos paklaidos ir klasifikavimo tikslumai po kiekvienos epochos, apmokant neuronų stochastiniu gradientiniu nusileidimu

Epocha	Treniravimo paklaida	Validavimo paklaida	Treniravimo tikslumas	Validavimo tikslumas
0	0,228246	0,263474	0,741758	0,705882
1	0,207602	0,182237	0,666667	0,735294
2	0,190138	0,226922	0,782051	0,735294
3	0,179191	0,163271	0,760073	0,794118
4	0,166576	0,204497	0,818681	0,764706
5	0,158765	0,152419	0,824176	0,838235
6	0,149868	0,184299	0,840659	0,779412
7	0,143954	0,147733	0,844322	0,823529
8	0,138170	0,167387	0,849817	0,808824
9	0,133828	0,145476	0,855311	0,838235
10	0,129982	0,154766	0,858974	0,823529
11	0,126782	0,142964	0,862637	0,838235
12	0,123973	0,145834	0,864469	0,823529
13	0,121499	0,139637	0,868132	0,838235
14	0,119282	0,139410	0,880952	0,838235
15	0,117276	0,135888	0,882784	0,838235
16	0,115446	0,134501	0,884615	0,838235
17	0,113766	0,132139	0,890110	0,838235
18	0,112213	0,130476	0,891941	0,838235
19	0,110771	0,128618	0,895604	0,838235
20	0,109425	0,126998	0,895604	0,852941
21	0,108164	0,125395	0,895604	0,852941
22	0,106976	0,123900	0,899267	0,852941
23	0,105854	0,122462	0,901099	0,852941

24	0,104791	0,121095	0,902930	0,852941
25	0,103779	0,119786	0,901099	0,852941
26	0,102815	0,118534	0,902930	0,852941
27	0,101893	0,117333	0,901099	0,852941
28	0,101009	0,116179	0,901099	0,852941
29	0,100160	0,115071	0,899267	0,852941
30	0,099343	0,114003	0,899267	0,852941
31	0,098556	0,112975	0,901099	0,852941
32	0,097796	0,111982	0,901099	0,852941
33	0,097060	0,111024	0,901099	0,852941
34	0,096348	0,110098	0,901099	0,852941
35	0,095658	0,109202	0,899267	0,882353
36	0,094988	0,108334	0,899267	0,882353
37	0,094337	0,107492	0,899267	0,882353
38	0,093704	0,106676	0,899267	0,882353
39	0,093088	0,105884	0,899267	0,882353
40	0,092487	0,105115	0,901099	0,897059
41	0,091902	0,104367	0,902930	0,897059
42	0,091330	0,103640	0,904762	0,897059
43	0,090772	0,102932	0,904762	0,911765
44	0,090227	0,102242	0,904762	0,911765
45	0,089694	0,101571	0,904762	0,911765
46	0,089173	0,100916	0,904762	0,911765
47	0,088663	0,100278	0,904762	0,911765
48	0,088163	0,099655	0,904762	0,911765
49	0,087673	0,099047	0,906593	0,911765
50	0,087194	0,098454	0,906593	0,911765
51	0,086723	0,097874	0,906593	0,911765
52	0,086262	0,097307	0,906593	0,911765
53	0,085809	0,096753	0,906593	0,911765
54	0,085365	0,096211	0,908425	0,911765
55	0,084928	0,095681	0,908425	0,926471
56	0,084500	0,095162	0,908425	0,926471
57	0,084079	0,094655	0,908425	0,926471
58	0,083665	0,094158	0,908425	0,926471
59	0,083258	0,093671	0,910256	0,926471
60	0,082857	0,093194	0,910256	0,926471
61	0,082463	0,092726	0,912088	0,926471
62	0,082076	0,092268	0,912088	0,926471
63	0,081695	0,091819	0,912088	0,926471
64	0,081319	0,091378	0,912088	0,926471
65	0,080950	0,090946	0,913919	0,926471
66	0,080586	0,090522	0,913919	0,926471
67	0,080227	0,090106	0,915751	0,926471
68	0,079874	0,089698	0,915751	0,926471
69	0,079526	0,089297	0,915751	0,926471
70	0,079183	0,088903	0,915751	0,926471
71	0,078844	0,088516	0,917582	0,926471
72	0,078511	0,088136	0,917582	0,926471

73	0,078182	0,087763	0,917582	0,926471
74	0,077858	0,087396	0,917582	0,926471
75	0,077538	0,087035	0,919414	0,926471
76	0,077222	0,086681	0,919414	0,926471
77	0,076910	0,086332	0,919414	0,926471
78	0,076603	0,085989	0,919414	0,926471
79	0,076299	0,085652	0,919414	0,926471
80	0,076000	0,085320	0,919414	0,926471
81	0,075704	0,084994	0,919414	0,926471
82	0,075412	0,084673	0,921245	0,926471
83	0,075123	0,084356	0,921245	0,926471
84	0,074838	0,084045	0,921245	0,926471
85	0,074557	0,083738	0,921245	0,926471
86	0,074278	0,083437	0,921245	0,926471
87	0,074004	0,083139	0,921245	0,926471
88	0,073732	0,082846	0,921245	0,926471
89	0,073464	0,082558	0,921245	0,926471
90	0,073198	0,082273	0,921245	0,926471
91	0,072936	0,081993	0,921245	0,926471
92	0,072677	0,081716	0,921245	0,926471
93	0,072421	0,081444	0,921245	0,926471
94	0,072167	0,081175	0,923077	0,926471
95	0,071917	0,080910	0,923077	0,926471
96	0,071669	0,080649	0,923077	0,926471
97	0,071424	0,080391	0,923077	0,926471
98	0,071181	0,080137	0,923077	0,926471
99	0,070941	0,079886	0,923077	0,926471
100	0,070704	0,079638	0,924908	0,926471
101	0,070469	0,079393	0,924908	0,926471
102	0,070237	0,079152	0,924908	0,926471
103	0,070007	0,078913	0,924908	0,926471
104	0,069779	0,078678	0,924908	0,926471
105	0,069554	0,078445	0,924908	0,926471
106	0,069331	0,078216	0,924908	0,926471
107	0,069110	0,077989	0,924908	0,926471
108	0,068891	0,077764	0,924908	0,926471
109	0,068675	0,077543	0,924908	0,926471
110	0,068461	0,077324	0,924908	0,926471
111	0,068249	0,077107	0,924908	0,926471
112	0,068039	0,076893	0,924908	0,926471
113	0,067830	0,076681	0,924908	0,926471
114	0,067624	0,076472	0,924908	0,926471
115	0,067420	0,076265	0,924908	0,926471
116	0,067218	0,076060	0,924908	0,926471
117	0,067018	0,075857	0,924908	0,926471
118	0,066819	0,075657	0,924908	0,926471
119	0,066623	0,075459	0,924908	0,926471
120	0,066428	0,075262	0,924908	0,926471
121	0,066235	0,075068	0,924908	0,926471

122	0,066044	0,074875	0,924908	0,926471
123	0,065854	0,074685	0,924908	0,926471
124	0,065666	0,074496	0,924908	0,926471
125	0,065480	0,074309	0,926740	0,926471
126	0,065295	0,074124	0,928571	0,926471
127	0,065112	0,073941	0,928571	0,926471
128	0,064931	0,073759	0,928571	0,926471
129	0,064751	0,073580	0,928571	0,926471
130	0,064573	0,073401	0,928571	0,926471
131	0,064396	0,073225	0,928571	0,926471
132	0,064221	0,073049	0,928571	0,926471
133	0,064047	0,072876	0,928571	0,926471
134	0,063875	0,072704	0,930403	0,926471
135	0,063704	0,072533	0,930403	0,926471
136	0,063535	0,072364	0,930403	0,926471
137	0,063367	0,072196	0,930403	0,926471
138	0,063200	0,072030	0,930403	0,926471
139	0,063035	0,071865	0,930403	0,926471
140	0,062871	0,071701	0,930403	0,926471
141	0,062708	0,071539	0,930403	0,926471
142	0,062547	0,071377	0,932234	0,926471
143	0,062386	0,071217	0,932234	0,926471
144	0,062228	0,071059	0,932234	0,926471
145	0,062070	0,070901	0,932234	0,926471
146	0,061914	0,070745	0,932234	0,926471
147	0,061758	0,070590	0,932234	0,926471
148	0,061604	0,070436	0,934066	0,926471
149	0,061452	0,070283	0,934066	0,926471

B Treniravimo duomenys ir optimalaus modelio išvestis

10 lentelė. Testiniai duomenys ir optimalaus neurono klasifikuotos reikšmės

Indeksas (iš pradinio rinkinio)	Tikroji reikšmė	Prognozuota reikšmė
222	0	0
454	0	0
74	1	1
666	1	1
51	0	0
382	1	1
120	0	0
583	1	1
253	1	1
602	1	1
674	0	0
600	0	0
423	0	0
613	1	1
626	0	0
593	1	1
15	0	0
236	0	0
516	0	0
36	0	0
244	1	1
104	1	1
537	1	1
592	1	1
533	0	0
151	0	0
432	0	0
421	1	1
208	1	1
0	0	0
515	1	1
167	1	1
443	0	0
665	1	1
228	0	0
64	1	0
281	0	0
42	1	1
179	0	0
552	1	1
200	0	0
419	1	1
330	1	1

338	0	0
379	1	1
407	0	0
97	0	0
292	0	0
201	0	0
159	0	0
164	0	0
96	0	0
668	0	0
187	0	0
35	0	0
301	1	1
102	0	0
360	0	0
607	0	0
474	1	1
562	0	0
119	0	0
23	0	0
229	1	1
675	0	0
655	1	1
536	1	1
481	0	0
101	0	0
